

面向学术论文的检索增强生成问答系统

刘家熙

2026 年 6 月 10 日

摘要

本文设计并实现了一个面向学术论文的端到端检索增强生成（RAG）问答系统。系统采用 Marker 解析 PDF，以 Tiktoken 进行 token 级分块，对比了 BGE-M3 和 Qwen3-Embedding 两种嵌入模型，利用 ChromaDB 存储向量，通过 BGE-reranker-v2-m3 精排与 MMR 多样性重排，最终由 DeepSeek-V4-Pro 生成答案并自动溯源。同时搭建了基于 LLM-as-Judge 的自动化评测框架，从召回率、MRR、引用准确率、答案正确率等多个维度进行量化评估。实验分析了不同分块大小（256/512/1024）、检索候选数（5/10）以及嵌入模型对系统性能的影响。结果表明，512 token 分块、top-5 检索结合 BGE-M3 或 Qwen3-Embedding 均可取得最优效果，其中 Qwen3-Embedding 在 Recall@5 和 MRR 上达到 0.976 和 0.957，验证了该 RAG 系统在此学术问答任务中的有效性。

1 引言

近年来，大语言模型在自然语言处理领域取得了显著进展，然而通用模型在特定学术领域的知识更新慢、容易产生幻觉。检索增强生成（RAG）技术通过引入外部知识库，可有效提升回答的准确性与可溯源性。针对学术论文问答场景，本文构建了一套完整的 RAG 系统流水线：从 PDF 解析、文本分块、向量化、检索重排到答案生成与自动化评测。系统支持中文提问，能够从 40 篇大模型相关论文中检索相关内容并给出引用来源（论文名、页码、chunk_id）。

本文的主要贡献包括：

- 实现了面向学术 PDF 的高质量解析与 token 级精准分块，支持页码溯源；
- 对比了 BGE-M3 与 Qwen3-Embedding 两种嵌入模型在不同分块尺寸和检索数量下的效果；
- 引入定义类查询增强、MMR 多样性重排、防幻觉约束与引用兜底策略；
- 搭建了基于 LLM-as-Judge 与混合语义匹配的自动化评测体系，提出兼顾整段与句子级的混合语义相似度度量，有效提升了长短证据场景下召回率、MRR、引用准确率及答案正确率的评估可靠性。

2 系统方法

2.1 整体架构

系统整体架构如图 1所示，其处理流程可划分为以下三个核心模块：

- 文档预处理与索引：采用 Marker 解析器提取 PDF 内容，结合 Tiktoken 进行语义感知的文本分块，并利用 Embedding 模型生成向量表征后存储于 ChromaDB；
- 多阶段检索与重排序：实施“粗检索—精排”级联机制，依次通过向量相似度匹配、Cross-Encoder 精细重排序及 MMR 多样性重排序策略，筛选上下文；
- 生成：将优化后的检索结果作为提示上下文结合用户提问，驱动大语言模型生成最终响应。




图 1: 系统整体架构流程

2.2 文档解析与分块

采用 Marker 工具解析学术 PDF，利用 GPU 加速输出 Markdown 格式文本。分块使用 Tiktoken (cl100k_base) 分词器，设置三组对照尺寸：256、512、1024 tokens，滑动窗口重叠 50 tokens，同时记录每个 chunk 的起始页码。

2.3 向量化与检索

嵌入模型对比：**BGE-M3**（1024 维）与 **Qwen3-Embedding-8B**（4096 维）。向量数据库采用 ChromaDB，批量写入。检索时先余弦相似度召回 top-20 候选，然后使用 BGE-reranker-v2-m3 (Cross-Encoder) 进行精排，再结合 MMR ($\lambda = 0.55$) 进行权衡候选上下文相关性与多样性，依次选出 top-k 个。对定义类问题（“是什么”“什么是”等）自动添加查询前缀以匹配明确定义段落，防止模型生成过于详细的细节内容。

2.4 答案生成

生成模型为 DeepSeek-V4-Pro。提示词包含检索到的上下文与用户问题，强制要求输出正文后分行列出引用来源（论文名、页码、chunk_id）。若模型未输出任何引用，系统自动补充检索 Top-1 块作为参考。对于信息不充足的问题，统一回答“根据已有信息，无法回答此问题”。

2.5 自动化评测

评测框架名为 `ContentBasedRAGEvaluator`，采用语义相似度匹配与 LLM 打分结合。下面定义四个核心指标。

2.5.1 Recall@k (二元命中)

对于单个问题，若前 k 个检索结果中至少有一个与任意标准证据 (Gold Evidence) 语义匹配，则判定为命中 (得分为 1)，否则为 0。计算公式为：

$$\text{Recall@k} = \frac{1}{N} \sum_{i=1}^N \mathbf{1} \left(\max_{1 \leq j \leq k} \text{sim}(c_{ij}, G_i) \geq \tau \right)$$

其中：

- N ：测试问题总数；
- c_{ij} ：第 i 个问题的第 j 个检索结果 (chunk)；
- G_i ：第 i 个问题的标准证据文本集合；
- $\text{sim}(c, G_i) = \max_{g \in G_i} [\max(\text{sim}_{\text{doc}}(c, g), \text{sim}_{\text{sent}}(c, g))]$ ，表示 chunk c 与证据集 G_i 的混合语义相似度。其中 sim_{doc} 为 chunk 全文与证据 g 的相似度， $\text{sim}_{\text{sent}} = \max_{s \in \text{Sent}(c)} \text{similarity}(s, g)$ 为 chunk 内各句子与 g 的最高相似度，取两者较大值以兼顾长、短证据的匹配场景；
- τ ：判定阈值 (本系统统一设为 0.75)；
- $\mathbf{1}(\cdot)$ ：指示函数，条件为真时取 1，否则为 0。

最终取所有问题的平均值作为系统整体的 Recall@k。

2.5.2 MRR (平均倒数排名)

MRR 衡量第一个相关结果的位置，公式为：

$$\text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i}$$

其中 rank_i 是第 i 个问题的第一个有效匹配结果在检索列表中的排名 (若没有匹配结果，则 $\frac{1}{\text{rank}_i} = 0$)。

2.5.3 引用准确率 (Citation Accuracy)

采用混合语义相似度匹配进行判断是否正确引用，评估模型生成答案时引用的正确性：

$$\text{Citation Accuracy} = \frac{TP}{TP + FP}$$

TP 为正确引用的数量 (引用的 chunk 确实包含答案所需证据)， FP 为错误引用的数量 (引用的 chunk 与答案无关或张冠李戴)。

2.5.4 答案正确率 (Answer Correctness F1)

基于知识点粒度评估答案的完整性和准确性：

$$F1 = \frac{TP}{TP + 0.5 \times (FP + FN)}$$

其中：

- TP ：正确回答的知识点数量；
- FP ：错误回答的知识点数量（幻觉）；
- FN ：标准答案中有但回答遗漏的知识点数量。

该指标由 LLM-as-Judge (Qwen2.5-32B-Instruct) 自动打分获得，当解析失败时回退到纯语义相似度判定。

此外，对于无标准答案的“不可回答问题”，模型正确拒答计满分，强行作答计零分，且不参与检索类指标计算。

3 实验设置

3.1 数据集

从 40 篇 RAG 相关论文 (2025.acl-long) 中构建测试集，包含 50 个“问题-参考答案-支持段落”三元组，其中有若干无答案的不可回答问题。

3.2 基线与变量

本实验重点进行消融分析，变量包括：

- 分块大小：256、512、1024 tokens；
- 精排后候选数 (top-k)：5、10；
- 嵌入模型：BGE-M3、Qwen3-Embedding-8B。

生成模型统一使用 DeepSeek-V4-Pro。评估时语义相似度阈值统一设定为 0.75（同时用于 Recall 和引用准确率判定）。

4 实验结果与分析

4.1 主要结果

表 1 展示了不同配置下的检索与生成性能。从表中可以得出以下观察：

- **分块大小**：512 tokens 在多数指标上优于 256 和 1024。256 分块因碎片化导致 Recall@1 偏低 (0.786-0.890)，但 Recall@5 较高 (最高 0.976)，说明碎片化分块虽牺牲首条命中率，但能通过更多候选覆盖证据。1024 分块因内容过长稀释关键信息，Recall@1 仅 0.738，且引用准确率明显下降 (BGE-M3 下低至 0.716)。

- **top-k 影响**: 对于 512 分块, top-5 相比 top-10 在引用准确率和回答正确率上更优 (例如 BGE-M3 下引用准确率 0.931 vs 0.897, 回答正确率 0.924 vs 0.875), 说明过多的候选可能引入噪声。对于 1024 分块, top-5 也优于 top-10 (如 Qwen3 引用准确率 0.726 vs 0.720)。
- **嵌入模型对比**: Qwen3-Embedding 在 Recall@1 和 MRR 上普遍优于 BGE-M3。例如 512 top-5 配置下, Qwen3 达到 Recall@1=0.929、MRR=0.945, 而 BGE-M3 为 0.881 和 0.909。但 BGE-M3 在引用准确率和回答正确率上略高 (0.931 vs 0.913, 0.924 vs 0.903)。在 1024 分块下, Qwen3 的引用准确率衰减更明显, 可能因其高维向量对长文本噪声更敏感。

表 1: 不同配置下的检索与生成性能

chunk_size	top-k	embedding 模型	Recall@1	Recall@3	Recall@5	MRR	引用准确率	回答正确率
512	5	BGE-M3	0.881	0.952	0.952	0.909	0.931	0.924
512	10	BGE-M3	0.929	0.952	0.952	0.937	0.897	0.875
256	5	BGE-M3	0.786	0.929	0.976	0.857	0.913	0.910
256	10	BGE-M3	0.810	0.952	0.976	0.875	0.845	0.915
1024	5	BGE-M3	0.738	0.857	0.929	0.809	0.793	0.849
1024	10	BGE-M3	0.738	0.857	0.929	0.809	0.716	0.866
512	5	Qwen3-Embedding	0.929	0.952	0.976	0.945	0.913	0.903
512	10	Qwen3-Embedding	0.952	0.952	0.976	0.957	0.875	0.900
256	5	Qwen3-Embedding	0.890	0.929	0.976	0.864	0.881	0.922
256	10	Qwen3-Embedding	0.810	0.929	0.976	0.860	0.855	0.922
1024	5	Qwen3-Embedding	0.738	0.881	0.929	0.807	0.726	0.903
1024	10	Qwen3-Embedding	0.738	0.881	0.929	0.808	0.720	0.894

4.2 最佳配置分析

综合各指标, **512 token 分块、top-5 检索、BGE-M3** 配置取得最佳平衡: Recall@5=0.952, MRR=0.909, 引用准确率 0.931, 回答正确率 0.924。若应用场景更侧重召回能力 (即希望尽可能覆盖正确答案), 则 **512 top-5 + Qwen3-Embedding** 更优, 其 Recall@5 达到 0.976, MRR 提升至 0.945。对于长文本分块 (1024), 无论哪种嵌入模型, 引用准确率均有明显下降, 不推荐使用。

5 结论

本文实现了一个完整的学术论文 RAG 问答系统, 覆盖了从 PDF 解析到自动评测的全流程。通过多组对照实验发现: 512 token 分块配合 top-5 检索效果最佳; Qwen3-Embedding 在召回和排序上优于 BGE-M3, 而 BGE-M3 在引用准确率方面略有优势; MMR 重排和定义类查询增强均能有效提升系统性能。未来的工作包括: 引入关键词与向量混合粗检索、记录历史对话以及优化跨论文比较类问题表现。